

MACHINE LEARNING

LES FONDAMENTAUX

Tout ce qu'il y a au tableau, remis dans l'ordre et complété : les étapes du ML, l'optimisation par moindres carrés et descente de gradient, les métriques, le sur-apprentissage et les deux parades classiques. Coche une section quand tu la tiens.

MODÈLE LINÉAIRE $\hat{y} = \sum a_i \cdot x_i + b$	LOSS (OLS) $L = \sum (\hat{y}_i - y_i)^2$	DESCENTE DE GRADIENT $a \leftarrow a - \alpha \cdot \partial L / \partial a$	BASELINE $\hat{y} = \bar{y}$
---	--	---	---------------------------------

Le fil rouge. Apprendre, c'est trouver les paramètres qui minimisent une fonction de coût sur le jeu d'entraînement. Évaluer, c'est vérifier sur des données jamais vues que le modèle généralise, et qu'il bat la baseline.

SECTION 01	VOCABULAIRE DE BASE Les mots qu'on retrouve partout	
TERME	DÉFINITION	EXEMPLE
Observation	Une ligne du dataset (individu, échantillon)	Un appartement
Variable (feature)	Une colonne d'entrée, notée $x_1, x_2, \dots, x_k$	Surface, nombre de pièces
Label (cible, target)	La colonne à prédire, notée y	Prix de l'appartement
Dataset	Tableau X de taille $n \times k$ et vecteur y de taille n	1 000 appartements, 4 variables
Modèle	Fonction qui relie X à y , définie par des paramètres	$\hat{y} = a_1 \cdot x_1 + a_2 \cdot x_2 + b$
Prédiction	Valeur produite par le modèle, notée $\hat{y}$ (« y chapeau »)	Prix estimé


TERME	DÉFINITION	EXEMPLE
Erreur (résidu)	Écart entre prédiction et vérité : $\hat{y} - y$	Estimé 200 k€, réel 180 k€ → 20 k€
Hyperparamètre	Réglage fixé <i>avant</i> l'entraînement, pas appris par le modèle	Taux d'apprentissage, degré du polynôme

Apprendre = trouver le lien entre les variables X et le label y à partir des données.

SECTION 02

LES DEUX FAMILLES D'APPRENTISSAGE

Supervisé ou non supervisé



FAMILLE	ON DISPOSE DE...	OBJECTIF	ALGORITHMES
Supervisé	X et y	Prédire y pour de nouvelles X	Régression linéaire, arbres, k-NN, SVM, réseaux de neurones
Non supervisé	X seulement	Découvrir une structure cachée	K-means (clustering), DBSCAN, ACP

- **Régression** : y est un nombre (prix, température, durée).
- **Classification** : y est une classe (spam / non spam, chat / chien).

SECTION 03


LE MODÈLE DE RÉGRESSION LINÉAIRE

Une somme pondérée des variables

$$\hat{y} = a_1 \cdot x_1 + a_2 \cdot x_2 + \dots + a_k \cdot x_k + b \quad \text{soit} \quad \hat{y} = \sum_{i=1 \rightarrow k} a_i \cdot x_i + b$$

- a_i : **coefficients** (poids), mesurent l'influence de chaque variable.
- b : **biais** (ordonnée à l'origine), souvent noté a_0 avec $x_0 = 1$.
- En une dimension, $\hat{y} = a \cdot x + b$ est une **droite** ajustée au nuage de points.

- Écriture matricielle : $\hat{y} = X \cdot a$ avec une colonne de 1 dans X pour le biais.



Exemple du tableau : après entraînement, l'algorithme a trouvé $\hat{y} = 3,5 \cdot x_1 + 2,2 \cdot x_2$. On l'applique ensuite à de nouvelles observations et on mesure $\hat{y} - y$.

SECTION

04

ÉTAPE 1 · OPTIMISATION

Trouver les paramètres qui minimisent la loss

1. On définit une **fonction de coût** (loss function) $L(a_1, a_2, \dots)$ qui mesure l'erreur globale du modèle.
2. On cherche les paramètres qui **minimisent** L .

MOINDRES CARRÉS ORDINAIRES (ORDINARY LEAST SQUARES, OLS)

$$L(a) = \sum_{i=1 \rightarrow n} (\hat{y}_i - y_i)^2$$

- Le carré empêche les erreurs positives et négatives de s'annuler.
- Il pénalise fortement les grosses erreurs.
- Sa version moyennée est la MSE (section 06).

DEUX FAÇONS DE TROUVER LE MINIMUM

MÉTHODE	PRINCIPE	AVANTAGES	LIMITES
Équation normale ANALYTIQUE	$a = (X^T X)^{-1} X^T y$	Exacte, aucun hyperparamètre	Coûteuse si beaucoup de variables (inversion de matrice)

MÉTHODE	PRINCIPE	AVANTAGES	LIMITES
Descente de gradient ITÉRATIVE	On part de paramètres aléatoires et on « descend la pente » de L	Marche pour tout modèle, gros datasets	Choix du taux d'apprentissage, peut être lente

DESCENTE DE GRADIENT, LA RÈGLE DE MISE À JOUR

$$a \leftarrow a - \alpha \cdot \partial L / \partial a$$


- α (alpha) = **taux d'apprentissage** (learning rate), la taille du pas.

TROP PETIT

 convergence très lente.

TROP GRAND

 on saute le minimum, la loss diverge.
- $\partial L / \partial a$ = gradient, direction de la plus forte montée. On va dans le sens opposé.
- On répète jusqu'à ce que la loss ne baisse plus (**convergence**).
- Variantes : *batch* (tout le dataset à chaque pas), *stochastique* (une observation), *mini-batch* (un petit paquet, le plus utilisé).



Astuce. Normaliser ou standardiser les variables (même échelle) accélère beaucoup la descente de gradient.

SECTION 05

ÉTAPES 2 ET 3 · VALIDATION PUIS ÉVALUATION

Pendant, puis après l'apprentissage

ÉTAPE	QUAND	QUESTION POSÉE	OUTILS
1. Optimisation	Entraînement	Quels paramètres minimisent la loss ?	OLS, descente de gradient
2. Validation	Pendant le développement	Le modèle généralise-t-il ? Quels hyperparamètres ?	Jeu de validation, courbes d'apprentissage (section 08)
3. Évaluation	À la toute fin, une seule fois	Quelle performance réelle sur des données inconnues ?	Jeu de test, métriques, baseline (section 06)

L'erreur mesurée sur le jeu d'entraînement est toujours optimiste : le modèle a déjà vu ces données. Seules les données jamais vues renseignent sur la **généralisation**.

SECTION 06

LES MÉTRIQUES DE RÉGRESSION

MSE, RMSE, MAE, R^2 et la baseline

Avec n observations, y_i la vraie valeur, $\hat{y}_i$ la prédiction et $\bar{y}$ la moyenne des y .

MÉTRIQUE	FORMULE	UNITÉ	LECTURE
MSE Mean Squared Error	$(1/n) \cdot \sum (\hat{y}_i - y_i)^2$	unité ²	Pénalise fortement les grosses erreurs. Sensible aux valeurs aberrantes.
RMSE Root MSE	$\sqrt{\text{MSE}}$	celle de y	Version interprétable de la MSE, l'« erreur typique ».
MAE Mean Absolute Error	$(1/n) \cdot \sum \hat{y}_i - y_i $	celle de y	Erreur moyenne brute. Plus robuste aux valeurs aberrantes.
R^2 coefficient de détermination	$1 - \frac{\sum (\hat{y}_i - y_i)^2}{\sum (y_i - \bar{y})^2}$	sans unité	Part de la variance de y expliquée par le modèle.

INTERPRÉTER R^2

- $R^2 = 1$ **PARFAIT** prédictions exactes.

- $R^2 = 0$ **BASELINE** pas mieux que prédire la moyenne $\bar{y}$.
- $R^2 < 0$ **ALERTE** le modèle fait pire que la moyenne.

LA BASELINE (MODÈLE DE RÉFÉRENCE)

Avant de juger un modèle, on le compare à un modèle « bête » :

- Régression : **prédire toujours la moyenne de y** , soit $\hat{y} = \bar{y}$. C'est exactement le modèle pour lequel $R^2 = 0$.
- Classification : prédire toujours la classe majoritaire.

Un modèle n'a d'intérêt que s'il **bat nettement la baseline**.

QUELLE MÉTRIQUE CHOISIR ?

- Grosses erreurs inacceptables → RMSE.
- Données avec valeurs aberrantes → MAE.
- Score global sans unité, facile à communiquer → R^2 .
- En pratique on en regarde plusieurs.

SECTION 07

SOUS-APPRENTISSAGE VS SUR-APPRENTISSAGE

Le compromis central du ML

SOUS-APPRENTISSAGE


underfitting · modèle trop rigide

- **Symptôme** : erreur élevée sur train **et** sur validation.
- **Cause** : pas assez de capacité, variables manquantes, entraînement trop court.
- **Image** : une droite pour modéliser une courbe.
- **Remèdes** : modèle plus complexe, ajouter des variables, entraîner plus longtemps.


SUR-APPRENTISSAGE

overfitting · modèle trop flexible, « collé » au dataset


- **Symptôme** : erreur faible sur train, élevée sur validation.
- **Cause** : trop de paramètres, pas assez de données, bruit appris par cœur.
- **Image** : une courbe qui passe par tous les points, bruit compris.
- **Remèdes** : plus de données, régularisation (Ridge, Lasso), simplifier, arrêt anticipé, validation croisée.



TROP RIGIDE



JUSTE



TROP FLEXIBLE

LE BON MODÈLE CAPTE LA TENDANCE SANS APPRENDRE LE BRUIT

COMPROMIS BIAIS / VARIANCE

- **Biais** élevé = modèle trop simple → sous-apprentissage.
- **Variance** élevée = modèle trop sensible aux données → sur-apprentissage.
- Le bon modèle est au milieu : assez souple pour capter la tendance, assez contraint pour ignorer le bruit.

SECTION 08

SOLUTION 1 · LE HOLD-OUT

Découper le dataset en train, validation et test

On ne doit **jamais** évaluer un modèle sur les données qui ont servi à l'entraîner : il les connaît déjà par cœur.



ajuster les paramètres

régler les hyperparamètres

PROPORTIONS INDICATIVES · 70/20/10, 80/10/10 OU 60/20/20 SELON LA TAILLE DU DATASET

JEU	RÔLE	UTILISÉ QUAND ?
Train	Le modèle apprend ses paramètres dessus	Pendant l'optimisation
Validation	Comparer modèles et hyperparamètres, surveiller l'overfitting	Pendant le développement
Test	Mesurer la performance de généralisation finale	Une seule fois, à la toute fin

RÈGLES À RESPECTER

- **Mélanger** (shuffle) les données avant de découper, sauf séries temporelles, qu'on découpe dans l'ordre chronologique.
- Le jeu de test doit rester vierge : s'il sert à choisir un modèle, il devient un jeu de validation et l'estimation finale est biaisée.
- **Fuite de données** (data leakage) : la normalisation, la moyenne, etc. se calculent sur le train seulement, jamais sur tout le dataset.

VALIDATION CROISÉE (K-FOLD)

Quand on a peu de données, on découpe le train en k parties (souvent 5 ou 10). Chaque partie sert tour à tour de validation et on moyenne les k scores. L'estimation est plus fiable qu'un seul découpage.


SECTION

09

SOLUTION 2 · COURBES D'APPRENTISSAGE

Monitoring de l'erreur train et validation

On trace **l'erreur (loss)** en fonction du **nombre d'observations n** utilisées pour entraîner (ou du nombre d'itérations), pour le train **et** la validation.



CE QU'ON OBSERVE	DIAGNOSTIC	ACTION
Train et val convergent vers une erreur basse	BON MODÈLE	Rien
Train et val convergent vers une erreur haute	SOUS-APPRENTISSAGE (biais)	Modèle plus complexe, meilleures variables

CE QU'ON OBSERVE	DIAGNOSTIC	ACTION
Train bas , val haut , écart persistant	SUR-APPRENTISSAGE (variance)	Plus de données, régularisation, simplifier
Les deux courbes descendent encore	Manque de données	Collecter plus d'observations
Val remonte au fil des itérations	Overfitting en cours	Arrêt anticipé (early stopping)

SECTION
10

LE PIPELINE COMPLET
De la donnée brute au modèle déployé

- 1. Données collecter, nettoyer, choisir les variables X et le label y
- 2. Découpage train / validation / test (mélanger d'abord)
- 3. Prétraitement normalisation, encodage (ajusté sur le train uniquement)
- 4. Choix modèle régression linéaire, arbre, ...
- 5. Optimisation minimiser la loss (OLS) par équation normale ou descente de gradient
- 6. Validation courbes d'apprentissage, hyperparamètres, détecter under/overfitting
- 7. Évaluation métriques (MSE, RMSE, MAE, R²) sur le TEST, comparer à la baseline
- 8. Déploiement utiliser le modèle sur de nouvelles données, surveiller la dérive

LES FORMULES À RETENIR

MODÈLE LINÉAIRE $\hat{y} = \sum a_i \cdot x_i + b$	LOSS OLS $L(a) = \sum (\hat{y}_i - y_i)^2$
ÉQUATION NORMALE $a = (X^T X)^{-1} X^T y$	DESCENTE DE GRADIENT $a \leftarrow a - \alpha \cdot \partial L / \partial a$
MSE $(1/n) \sum (\hat{y}_i - y_i)^2$	RMSE $\sqrt{MSE}$
MAE $(1/n) \sum \hat{y}_i - y_i $	R² $1 - \sum (\hat{y}_i - y_i)^2 / \sum (y_i - \bar{y})^2$
BASELINE RÉGRESSION $\hat{y} = \bar{y} \quad (R^2 = 0)$	

AUTO-ÉVALUATION

Dix questions flash, réponses masquées

Quelle est la différence entre apprentissage supervisé et non supervisé ?

1 Supervisé : on a le label y et on veut le prédire. Non supervisé : pas de label, on cherche une structure (clustering, réduction de dimension).

Que représente $\hat{y}$? Et $\hat{y} - y$?

2 $\hat{y}$ est la prédiction du modèle ; $\hat{y} - y$ est l'erreur, ou résidu.

Pourquoi élève-t-on l'erreur au carré dans les moindres carrés ?

3 Pour que les erreurs positives et négatives ne s'annulent pas, et pour pénaliser davantage les grosses erreurs.

Que se passe-t-il si le taux d'apprentissage est trop grand ? Trop petit ?

4 Trop grand : la loss diverge, on saute le minimum. Trop petit : la convergence est très lente.

Quelle métrique a la même unité que y : MSE ou RMSE ?

5 RMSE. La MSE est en unité au carré.

Que signifie un R^2 négatif ?

6 Le modèle fait pire que prédire simplement la moyenne de y , c'est-à-dire pire que la baseline.

Pourquoi ne doit-on pas évaluer le modèle sur le jeu d'entraînement ?

7 Il connaît déjà ces données : le score serait optimiste et ne mesurerait pas la généralisation.

À quoi sert le jeu de validation, par rapport au jeu de test ?

8 Validation : choisir le modèle et les hyperparamètres. Test : estimation finale, une seule fois, sans jamais influencer les choix.

Sur une courbe d'apprentissage, comment reconnaît-on le sur-apprentissage ?

9 Erreur de train basse, erreur de validation nettement plus haute, et un écart qui ne se referme pas quand n augmente.

Citez trois remèdes contre le sur-apprentissage.

Plus de données, régularisation (Ridge, Lasso), modèle plus simple, arrêt anticipé, validation croisée.

NOTES DE RÉVISION

- **Source** : les notes du tableau (étapes du ML, optimisation, métriques, problèmes et solutions). Les définitions, l'équation normale, le compromis biais / variance, la validation croisée et la fuite de données ont été ajoutés pour compléter.
- **Notation** : n est le nombre d'observations, k le nombre de variables. Le tableau utilise $\sum (i = 1 \rightarrow N)$ pour la loss et $\sum (i = 1 \rightarrow k)$ pour le modèle : ce ne sont pas les mêmes indices.
- **Progression** : les sections cochées sont mémorisées dans ce navigateur uniquement. « Réinitialiser » les décoche toutes.
- **Impression** : la page s'imprime sans les contrôles, une section par bloc.